

Agosto 2025

LIMPIEZA Y PREPARACIÓN DE DATOS

ESTABLECIMIENTOS EDUCATIVOS

Sofía García
Julio García Salas
Joaquin Campos

Estado inicial

El dataset original contenía 16,414 filas y 17 columnas.

Problemas detectados:

- Varias columnas con nombres largos o inconsistentes.
- Presencia de algunos valores nulos, TELEFONO (424 faltantes), DIRECTOR (63 faltantes) y DIRECCION (10 faltantes).
- Otros datos textuales con acentos, min/MAYUS y caracteres especiales.
- Mismas escuelas en dos sectores o áreas diferentes.
- Numeros de teléfono incompletos o no disponibles.

EXACTITUD Y PRECISIÓN EN LA LIMPIEZA DE DATOS

01

Exactitud en este caso que “conformen” mejor la realidad:

- Consistencia geográfica
- Mineo de tokens
- Estandarización de direcciones

02

Precisión en este caso que la misma entidad se represente siempre igual:

- Las llaves canónicas
- Normalización léxica de textos
- Estandarización de teléfonos

CONSISTENCIA GEOGRÁFICA Y DIRECCIONES

01

PROBLEMA:

Escuelas asociadas a mas
de un área.

Solución

- Validación con diccionarios oficiales de municipios/departamentos.
- Ajuste de registros incorrectos para garantizar consistencia.



En direcciones:

- Eliminación de espacios dobles y símbolos.
- Conversión a formato estándar.


DETECCIÓN DE INCONSISTENCIAS

MINERIA DE TOKENS

01 CÓMO?

- Se construyó un catálogo de tokens **urbanos** (ZONA, AVENIDA, BARRIO, COLONIA, BULEVAR) y **rurales** (ALDEA, CASERÍO, CANTÓN, KM, FINCA).
- Según la presencia de tokens, se ajustó el valor de AREA (URBANA/RURAL) cuando había conflictos.

02 RESULTADOS(ALGUNOS)



DETECCIÓN DE INCONSISTENCIAS

MINERIA DE TOKENS

token	RURAL	URBANA	total	p_urbana
ZONA	0	6102	6102	1
CABECERA	0	415	415	1
4TA	0	237	237	1
MIXCO	0	155	155	1
10A	0	99	99	1

token	RURAL	URBANA	total	p_urbana
5TA	1	174	175	0,994
AVENIDA	25	3193	3218	0,992
1RA	1	114	115	0,991
6TA	1	94	95	0,989
DIAGONAL	1	88	89	0,989

DETECCIÓN DE DUPLICADOS

Normalización de textos

01

Conversión a mayúsculas para evitar duplicados falsos

02

Eliminación de símbolos especiales

03

Estandarización de direcciones

```
reemplazos = [  
    (r'\bAV\.\b', 'AVENIDA'),  
    (r'\bAV\b', 'AVENIDA'),  
    (r'\bAVE\.\?\b', 'AVENIDA'),  
    (r'\bAVDA\.\?\b', 'AVENIDA'),  
    (r'\bBLVD\.\?\b', 'BULEVAR'),  
    (r'\bCALZ\.\?\b', 'CALZADA'),  
    (r'\bCARR\.\?\b', 'CARRETERA'),  
    (r'\bZN\b', 'ZONA'),  
    (r'\bZ\.\b', 'ZONA'),  
    (r'\bZ\.\?\b', 'ZONA'),  
    (r'\bKM\.\?\b', 'KM'),  
    (r'\bNO\.\?\s+(\d+)\b', r'NO \1')
```

REVISIÓN Y LIMPIEZA DE TELÉFONOS

NORMALIZACIÓN

01

424 teléfonos (NO DISPONIBLE) ($\approx 2.6\%$ de la base).

Problemas

02

- Formatos variados: algunos con guiones, otros con espacios.
- Presencia de caracteres no numéricos.

Acción tomada

03

- Dejamos solo digitos con regex
- Columnas con valores ausentes se rellenaron con vacío
- No eliminamos registro.

EXACTITUD TELEFÓNICA

NORMA

01

Problema

- EN GUATEMALA EL 18 DE SEP DEL 2004 SE HIZO EL CAMBIO DE 7 DÍGITOS A 8

02

SOLUCIÓN

- **Móvil:**
 - Se agrega el 5 antes.
- **Fijo:**
 - Metropolitano: Se agrega antes el 2.
 - Suburbano: Se agrega antes el 6.
 - Interurbano: Se agrega antes el 7.



VALIDACIÓN FINAL Y RESULTADOS

Comparación entre dataset inicial y final:

- Se mantuvo el mismo número de filas (16,414)
- Se redujo el número de duplicados y valores inconsistentes.
- Mejoras significativas en:
 - Consistencia geográfica.
 - Uniformidad en direcciones.
 - Limpieza en teléfonos y nombres.